Materials Informatics

第一原理計算を、機械学習で代替する

無機半導体のゼーベック係数予測 — 15,479 材料

氏名・所属

データ: Materials Project / MPContribs carrier_transport (Ricci et al., Sci. Data 4, 170085, 2017, CC-BY 4.0)

課題

熱電材料の探索は、計算コストで止まる

1 材料の輸送物性を得るのに、DFT バンド構造計算 + BoltzTraP 輸送計算が必要

候補となる無機化合物は数万件 – 全部は回せない

→ **「計算する前に、有望なものを絞り込みたい」**

アプローチ

すでに計算済みの 15,479 件から、予測モデルを学習する

入力：組成と、データベース登録値（バンドギャップ・密度・対称性）

出力：ゼーベック係数 S（p 型・n 型）

→ **高コスト計算の「代理モデル」として、スクリーニングを高速化する**

パイプライン

一方向の 5 段構成 — 前段の出力だけが次段の入力

データ源	`MPContribs carrier_transport + MP summary`	2 つのデータベース
取得・結合	`transport/get_transport_data.py`	transport_dataset.csv — 15,479 材料
特徴量化	`transport/featurize.py`	features_dataset.csv — 145 次元
学習・評価	`transport/train.py`	metrics.json ／ パリティ図 ／ SHAP
可視化	`web/build_data.py → web/build_single.py`	ダッシュボード(単一 HTML)

各段は独立に再実行できる。中間 CSV とモデルはコードから再現できるため git には置かない。

データ構築

3 万件のうち、学習に使えたのは 1.5 万件

30,467	MPContribs の非金属エントリ
22,623	現行の Materials Project と結合できたもの
15,682	安定相フィルタ E_hull ≤ 0.05 eV/atom
15,479	**登録バンドギャップ > 0 ← 学習データ**

古典的な熱電材料(Bi_2Te_3・SnSe・Mg_2Si・ZrNiSn・$CoSb_3$)が残っていることを毎回自動確認している。

設計の要点 ①

予測値のカスケードを、あえて禁止する

特徴量のバンドギャップは、モデルの予測値ではなくデータベース登録値を使う

予測値を次段に渡すと、その誤差がそのまま下流に伝染する

精度が悪いとき「モデルが悪いのか、渡された入力が悪いのか」を切り分けられなくなる

→ 入力を登録値に固定し、各モデルを独立に評価できる状態を保つ

設計の要点 ②

答えと同じ計算から出た量は、特徴量に入れない

有効質量 m* は、目的変数とまったく同じ BoltzTraP 計算の産物

入れれば精度は上がる。ただしそれは「リーク」であって実力ではない

キャリア濃度も除外 — 全材料で 10^{18} cm^{-3} に固定され、情報量がゼロだから

→ 見かけの精度より、評価の健全さを優先する

結果

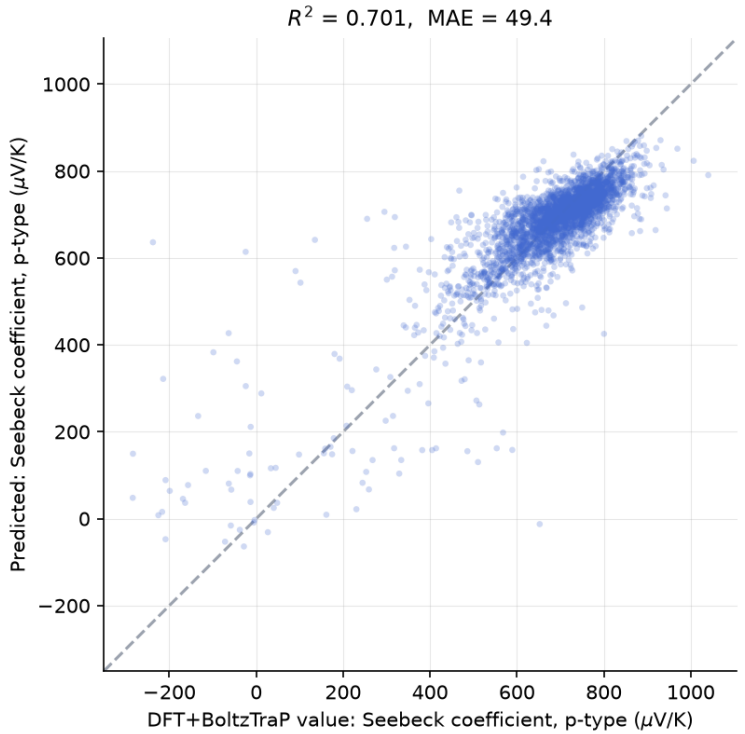
未学習の 3,096 材料で R^2 = 0.70 / 0.73

平均絶対誤差　49.4 μV/K(p 型) ／ 54.3 μV/K(n 型)

5-fold 交差検証 R^2 = 0.68 ± 0.03 – まぐれではない

ランダムフォレスト回帰(決定木 300 本)・80 : 20 分割

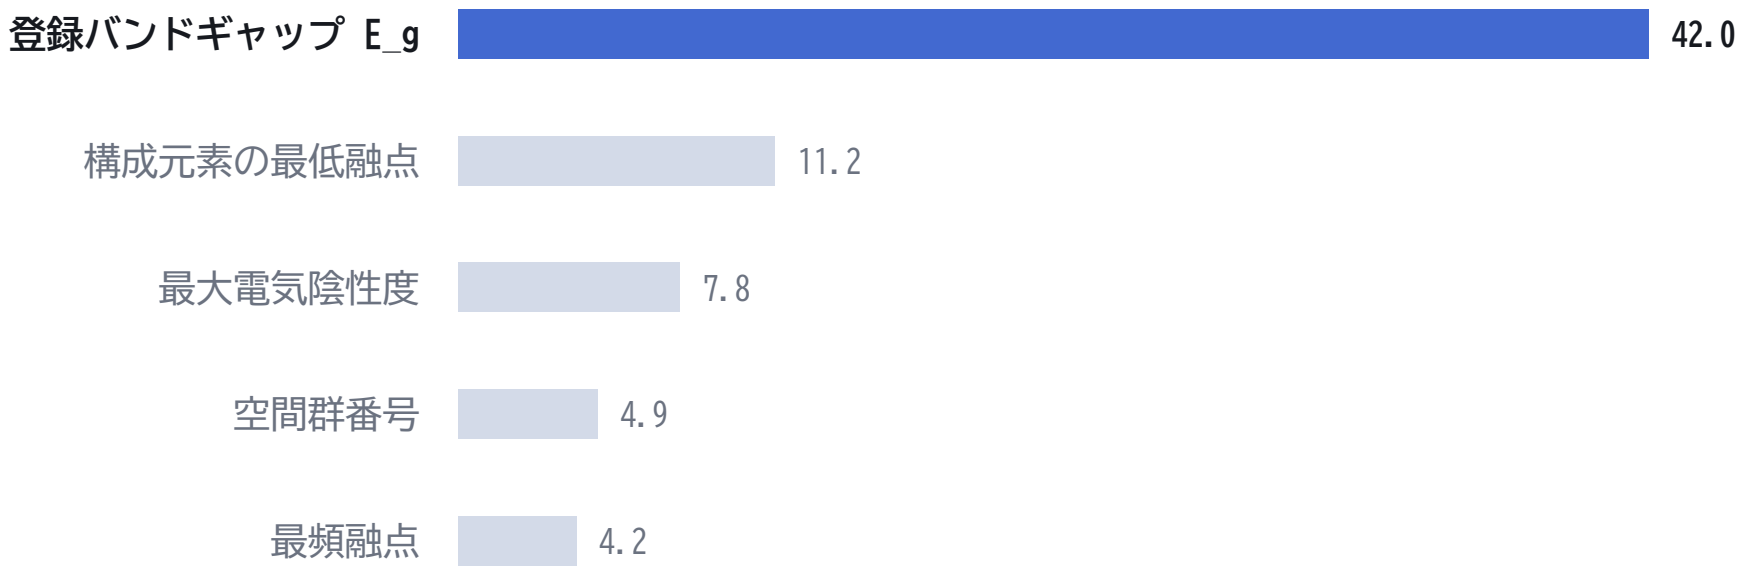
→ 計算を回さずに、有望な材料を絞り込める水準



横軸 = 計算値、縦軸 = 予測値(p 型)

発見

145 特徴量のうち、バンドギャップが単独 1 位



平均 |SHAP| 値(p 型・上位 5)。1 位は 2 位の 3.8 倍。

小さいギャップが S を抑制する向きに効いており、バイポーラ伝導の物理と整合する。

限界と次の一手

予測しているのは「実験値」ではなく「計算値」

目的変数は GGA + BoltzTraP の計算値。GGA はバンドギャップを系統的に過小評価する

300 K・キャリア濃度 10^{18} cm^{-3} の 1 点に固定。温度依存性はまだ扱えていない

→ 次：実験データセット（UCSB 熱電など）での検証と、温度依存への拡張

まとめ

代理モデルを作り、物理の因果をデータで裏付けた

15,479 材料 × 145 特徴量 → ゼーベック係数を R^2 0.73 で予測

設計原則は 2 つ：予測値のカスケード禁止と、リーク源の明示的な除外

SHAP がバンドギャップを 1 位に選び、設計の出発点だった物理仮説を裏づけた